2025 年上海市高等学校信息技术水平考试试卷

二三级 数据科学技术及应用（A 场）

（本试卷考试时间 150 分钟）

一、单选题（ 本大题 10 道小题 ，每小题 2 分，共 20 分），从下面题目给出的 A、B、C、D 四个可供选择的答案中选择一个正确答案。

1. 无人机通过搭载的传感器搜集农场周边环境数据信息，这种获取数据的方法称为_____。

A. 人工采集

B. 设备采集

C. 系统日志采集

D. 网络爬虫采集

2. 下表给出了某电商网站2023年畅销图书数据，对于表中的空缺数据，合理的处理方式是_____。

排序	书名	作者	原价	折扣比例	评论数
1	我与地坛（纪念版）	史铁生	29	6	1333454
2	额尔古纳河右岸	迟子建	32	5	954081
3	活着	余华	45	6.9	1462360
4	长安的荔枝	马伯庸	45	6.4	478870
5	第七天	余华	49	6.9	560246
6	三体：全三册	刘慈欣	93	5	2351373
7	你当像鸟飞往你的山	塔拉	59	6	1701192
8	瓦尔登湖	梭罗	26.8		211657
9	作家榜名著：月亮与六便士	毛姆	39.8	4.2	1587510
10	苏东坡传	林语堂	52	5	1117882

A. 删除排序为 8 的行

B. 删除折扣比例这列

C. 用折扣比例的平均值替换空值

D. 用 0 填充空值

3. 学院评选一位“最受毕业生喜爱的老师”，可以通过统计学生投票的_____指标实现。

A. 均值

B. 方差

C. 中位数

D. 众数

4. 下列体现大数据特征的应用场景是_____。

A. 使用 Excel 生成数据透视表

B. 大模型使用互联网上过去数十年的文本、图像数据训练模型

C. 大学班级内问卷调查

D. 统计一篇文章中词的出现频率

上海市教育考试院 版权所有

5.某平台分析大学生常用的手机品牌，_____适合展示各品牌的使用比例。
A.直方图
B.饼图
C.折线图
D.箱须图

6.数据智能主要依赖于_____技术从大量数据中提取有价值的信息。
A.人工智能
B.传统数据库查询
C.手工数据分析
D.简单的统计计算

7.某充值消费商家希望根据用户历史充值时间、金额、消费记录等数据，预测下一次充值的时间和金额，以便进行个性化促销活动，应建立_____分析模型实现。
A.分类
B.回归
C.聚类
D.关联规则

8.2024 年 5 月，武汉街头出现了无人驾驶萝卜快车，这种快车主要采用_____技术来识别十字路口。
A.图像识别
B.语音识别
C.文本识别
D.后台人工识别

9.通过收集本市近十年苹果的产量和售价数据，预测本市明年的苹果价格，主要采用的是_____。
A.文本分类技术
B.数据降维技术
C.时序分析技术
D.图像识别技术

10.文旅局采用_____技术分析游客在社交平台上对热门景点的评价，了解游客的满意度。
A.文本分类
B.语音识别
C.文本聚类
D.机器翻译

二、多选题（ 本大题 5 道小题 ，每小题 2 分，共 10 分），从下面题目给出的 A、B、C、D 四个可供选择的答案中选择所有正确答案。

1.数据科学的知识结构主要由_____组成。
A.生活常识

上海市教育考试院 版权所有

B. 数学
C. 计算机科学
D. 领域专业知识

2. 社交平台收集了博主发布视频的订阅量，为了考察订阅量的分布情况，通常采用以下_____方法。
A. 绘制订阅量的饼图
B. 删除订阅量缺失的数据
C. 计算订阅量均值和标准差
D. 绘制订阅量的直方图

3. 图像数据分析的应用场景包括_____。
A. 家庭视频监控报警
B. 血液生化指标检验
C. 分析 X 光片进行疾病诊断
D. 微信聊天中发送语音信息

4. 以下_____监督学习方法通过学习历史数据的事实知识，建立未知数据的预测模型。
A. 线性回归
B. 聚类
C. 朴素贝叶斯
D. 随机森林

5. 多模态大模型能够基于文本描述生成包含相关内容的图像，主要采用了_____等技术。
A. 大规模预训练模型（Transformer）
B. 文本图像语义表示对齐
C. 跨模态学习
D. 循环神经网络（RNN）

三、操作题

（一）简答题（本大题2道小题 ，每小题8分，共16分）

提示：打开C:\KS\answer.docx文件，将答案填写在该文件的相应题目下并保存。

1. 分位数是常用的数据分析统计概念，以高中结业考的赋分制（按分数排名比例划分10个等第成绩）为例说明分位数的使用方法。

2. 某品牌生鲜连锁超市计划在某市开设多家分店，企业获取了该市的居民住宅区的经纬度数据，简述企业应如何利用K-means方法进行决策，确定开设分店数目和分店的选址。

（二）分析操作题（ 本大题4道小题 ，每小题16分，共64分）。

提示：可选择任意分析工具或编写Python程序实现分析过程。

1）选择工具软件实现，请将分析结果截图拷贝到C:\KS\answer.docx文件中对应的题目后。

上海市教育考试院 版权所有

2）选择Python编程实现，可参考题目提供的源程序，补充缺少的代码后调试运行，查看结果。请将补充的代码填写到C:\KS\answer.docx文件中对应的题目后，并黏贴运行结果截图。

3）Python源程序、数据文件存放在"C:\KS"文件夹下，供程序调试；Python科学计算库函数使用说明存放在"C:\KS"文件夹下，注意不同类库的函数存放在相应的sheet下。

1. 联合院线2024年4月份放映3部动画电影["你想活出怎样的人生", "名侦探柯南", "数码宝贝02"]，使用随机实验数据模拟票房情况。数据分析的具体要求如下。
   1）随机生成一个 [0,30)万元范围内均匀分布的二维浮点数数组，表示15家影院3部电影的票房；
   2）计算每一家影院的4月份动画电影票房的总收入；
   3）统计4月份票房总收入不足30万元的影院个数；
   4）统计每部动画电影的平均票房，输出平均票房最高的动画电影名称。

   Python编程实现：源程序文件fill_1.py

```
import numpy as np
import pandas as pd
#设置亚洲文字显示宽度
pd.set_option("display.unicode.east_asian_width",True)
pd.set_option("display.unicode.ambiguous_as_wide",True)
films=["你想活出怎样的人生", "名侦探柯南", "数码宝贝02"]

#1）随机生成一个 [0,30)万元范围内均匀分布的二维浮点数数组，表示15家影院3部电影的票房
booking = 【1】(0,30,(15,3))
#2）计算每家影院的4月份动画电影票房的总收入
totals = booking.sum(【2】)
#print(totals)
#3）统计4月份每家影院动画电影票房的总收入票房收入不足30万元的影院个数
print(f"有{【3】.size}家影院4月份动画电影票房不足30万元")
#4）统计每部动画电影的平均票房，输出平均票房最高的动画电影名称
film_booking = booking.mean(axis = 0)
#print(film_booking)
print(f"票房最高的动画电影是：{films[【4】]}")
```

2. 文件RestHome.csv记录了上海养老机构信息，统计分析其中的各区民营养老机构的床位数，具体要求如下。
   1）从文件RestHome.csv读入数据，选取性质为民营的养老机构的区和床位数信息；
   2）统计不同区的床位总数；
   3）按床位总数降序排列各个区(替换原数据)；
   4）绘制饼图反映各区床位数的分布情况。

   Python编程实现：源程序文件fill_2.py

```
import numpy as np
import pandas as pd
```

上海市教育考试院 版权所有

```
import matplotlib.pyplot as plt
#设置亚洲文字显示宽度
pd.set_option("display.unicode.east_asian_width",True)
pd.set_option("display.unicode.ambiguous_as_wide",True)

#1）从文件RestHome.csv读入数据，选取性质为民营的养老机构的区和床位数信息
RestHomes = pd.read_csv("RestHome.csv",encoding ="gbk")
po_RestHomes = RestHomes.loc[【1】,["区","床位数"]]
print(po_RestHomes)
#2）统计不同区的床位总数
tHomes = po_RestHomes.【2】.sum()
#3）并按床位总数降序排列(替换原数据)
tHomes.【3】(by = ["床位数"],ascending=False,inplace=True)
print(tHomes)
#4）绘制饼图反映各区床位数的分布情况
plt.rcParams['font.sans-serif']= ['SimHei']
tHomes["床位数"].【4】(autopct='%4.1f%%',figsize=(10,8))
plt.title("上海各区民营养老机构床位数分布图")
plt.show()
```

3. 文件gold_data.csv中存放了2012年至2022年黄金交易数据。在处理了缺失数据后，统计2022年金价的平均收盘价。具体要求如下：

1）读取gold_data.csv文件中的数据；
2）判断数据中是否有空值，并输出各列的空值情况；
3） Volume列缺失的值，使用Volume值的均值进行填充；
4）计算2022年金价的平均收盘价(Close/Last)。

Python编程实现：源程序文件fill_3.py

```
import pandas as pd
#设置亚洲文字显示宽度
pd.set_option("display.unicode.east_asian_width",True)
pd.set_option("display.unicode.ambiguous_as_wide",True)
#1）读取gold_data.csv文件中的数据
data= pd.【1】('gold_data.csv')
print(data.head())
#2）判断数据中是否有空值，并输出各列的空值情况；
is_NAN = data.【2】.any()
print(is_NAN)
#3）Volume列缺失的值，使用Volume值的均值进行填充
data['Volume'].【3】
# 将Date列的数据类型转换为datetime
data['Date'] = pd.to_datetime(data['Date'])
#4）计算2022年金价的平均收盘价(Close/Last)
jj=data.loc[data["Date"]>='01/01/2022','Close/Last']
```

上海市教育考试院 版权所有

print("2022年金价的平均收盘价：{:.2f}".format(【4】))

4．表1和表2分别记录了我国2022年6月部分城市轨道交通运营数据，请用这些数据进行统计分析。具体要求如下：

1) 2022年6月城市轨道交通部分运营数据如表1和表2所示，将相同城市的数据进行合并输出，结果如表3所示；

2) 创建南京城市轨道交通运营数据表：[13, 426.4, 7503.6, 4104.1]；

3) 将南京城市轨道交通运营数据添加到表3中；

4) 查询上海城市轨道交通运营数据并输出。

表1 2022年6月某些城市轨道交通部分运营数据I

城市	运营线路数	运营里程（公里）
上海	20	825
北京	27	783
广州	18	609.8
成都	13	557.8
武汉	14	478.6
杭州	11	450.5
重庆	10	434.6
深圳	13	431

表2 2022年6月某些城市轨道交通部分运营数据II

城市	客运量（万人次）	进站量（万人次）
上海	15916.1	8630.4
北京	14478.9	7911.1
广州	23014.7	12528.9
成都	15941.6	8992.5
武汉	9421.2	6034.1
杭州	8689.9	5329.5
重庆	9691.3	6377.1
深圳	16729.3	10127.5

表3 表1和表2合并后的表

城市	运营线路数	运营里程（公里）	客运量（万人次）	进站量（万人次）
上海	20	825	15916.1	8630.4
北京	27	783	14478.9	7911.1
广州	18	609.8	23014.7	12528.9
成都	13	557.8	15941.6	8992.5
武汉	14	478.6	9421.2	6034.1
杭州	11	450.5	8689.9	5329.5
重庆	10	434.6	9691.3	6377.1
深圳	13	431	16729.3	10127.5

Python编程实现：源程序文件fill_4.py

```
import pandas as pd
#设置亚洲文字显示宽度
```

```
pd.set_option("display.unicode.east_asian_width",True)
pd.set_option("display.unicode.ambiguous_as_wide",True)

#保存表df1和表df2中的2022年6月部分城市轨道交通部分运营数据
ds1=pd.DataFrame({'城市':['上海','北京','广州','成都','武汉','杭州','重庆','深圳'],
                  "运营线路数":[20, 27, 18, 13, 14, 11, 10, 13],
                  "运营里程（公里）":[825.0, 783.0, 609.8, 557.8, 478.6, 450.5,
434.6, 431.0]})
ds2=pd.DataFrame({'城市':['北京', '成都', '广州', '杭州', '上海', '深圳', '武汉', '重庆'],
                  "客运量（万人次）":[14478.9, 15941.6, 23014.7, 8689.9, 15916.1,
16729.3, 9421.2, 9691.3],
                  "进站量（万人次）":[7911.1, 8992.5, 12528.9, 5329.5, 8630.4,
10127.5, 6034.1, 6377.1]})

#1) 将两个数据对象中相同城市的数据合并输出
ds=pd.【1】(ds1,ds2,on="城市")
print(ds)
#2) 添加南京城市轨道交通运营数据
ds3=[['南京', 13, 426.4, 7503.6, 4104.1]]
ds3=pd.DataFrame(ds3,columns=【2】)
#3) 合并数据到df中
ds=pd.【3】([ds,ds3],axis=0)
print("2022年6月城市轨道交通运营状况：", ds)
#4)查询上海城市轨道交通运营数据
print("2022年6月上海城市轨道交通运营状况：", ds.loc[【4】,:])
```

（三）综合应用题（共10小题，共40分）

提示：打开"C:\KS"文件夹下的程序文件"prog.py"，按照程序注释说明，编写代码实现功能要求。

数据集happiness.csv中记录了与幸福感有关的诸多变量，如户口类型、年龄、家庭年收入、家庭常驻人口、家庭经济状况、是否参加基本医疗保险、是否参加基本养老保险、是否参加商业医疗保险、是否参加商业养老保险、养老应该由谁负责等（见happiness数据集说明文件.txt）。利用提供的数据建立模型来预测幸福感并对模型进行性能评估。具体要求如下：

1) 从文件happiness.csv中读出所需的数据；(3分)
2) 对数据集进行预处理，将【幸福感】的值转换成数值型并保存为新特征列【幸福值】，转换原则为：{'非常不幸福':1,'比较不幸福':2,'说不上幸福不幸福':3, '无法回答':3,'比较幸福':4,'非常幸福':5}；(6分)
3) 利用独热编码方式将【养老应该由谁负责】特征值转换成数值；(4分)
4) 统计【幸福感】特征值的占比情况，并绘制饼图进行可视化呈现；(5分)
5) 计算各特征项与预测目标项【幸福值】之间的相关系数，筛选出与目标特征【幸福值】相关程度最高的特征项；(3分)
6) 用【幸福感】和【幸福值】以外的特征项与目标特征【幸福值】构成数据集；(3分)
7) 将数据集按照合适比例分为训练集和测试集；(3分)

上海市高考考试院 版权所有

8) 至少选用两种建模方法在训练集上建立分类模型，并给出模型的分类性能；(6分)

9) 在测试集上测试各模型的性能，生成分类性能报告；(4分)

10) 根据第9）步的运行结果，说明分类模型用于预测的效果，比较选用模型的性能，填写在程序文件给出的注释行中。(3分)

上海市教育考试院
版权所有