2025 年上海市高等学校信息技术水平考试试卷

四级 大数据与云计算（A 场）

（本试卷考试时间 150 分钟）

一、单选题（ 本大题 20 道小题 ，每小题 1 分，共 20 分），从下面题目给出的 A、B、C、D 四个可供选择的答案中选择一个正确答案。

1. Linux 是云计算平台中常用的操作系统，其____命令可以实时监控磁盘 I/O 性能。

A. iostat

B. netstat

C. vmstat

D. lsof

2. ____协议可用于域名解析。

A. DNS

B. ARP

C. FTP

D. SMTP

3. 对象存储的核心特征是____。

A. 通过唯一 ID 而非文件路径访问数据

B. 支持块级数据的访问

C. 仅适用于结构化的数据

D. 必须与虚拟机绑定使用

4. Kubernetes 中，资源对象____管理无状态应用。

A. Deployment

B. StatefulSet

C. DaemonSet

D. Job

5. DevOps 的核心理念是持续集成和持续部署，属于 CI/CD 工具的是____。

A. Jenkins

B. MySQL

C. Nginx

D. Redis

6. GPU 在云计算与 AI 场景中的主要作用是____。

A. 并行计算加速

B. 网络转发

C. 数据加密

D. 存储备份

上海市教育考试院 版权所有

7.大数据的特点不包括____。
A.价值密度高
B.多结构化数据
C.增长速度快
D.巨大的数据量

8.MapReduce 编程模型对数据流的处理过程包含① Splitting ② Shuffling ③ Input ④ Mapping ⑤ Reducing ，正确的处理顺序是____。

A.③①④②⑤
B.①③②④⑤
C.②⑤③①④
D.④⑤①③②

9.HDFS 中负责存储实际数据块的组件是____。
A.DataNode
B.Standby NameNode
C.Active NameNode
D.ResourceManager

10.____不是 Zookeeper 的功能。
A.存储大量数据
B.管理配置信息
C.管理集群节点
D.实现分布式锁

11.HBase 的数据库类型是____。
A.列式存储数据库
B.文档型数据库
C.关系型数据库
D.图数据库

12.YARN 架构中负责监控应用执行和资源分配的组件是____。
A.ResourceManager
B.NodeManager
C.ApplicationMaster
D.JobTracker

13.在 Hive 中，对于 INSERT … SELECT 语法的描述不正确的是____。
A.对于分桶表数据写入，除 INSERT INTO 以外，还可以使用 LOAD DATA 方式
B.通过单次插入将查询结果导入表或分区
C.可以使用 INSERT OVERWRITE 覆盖表中原数据
D.使用 INSERT INTO 不会覆盖表中原数据

上海市教育考试院 版权所有

14.关于 Flink 的描述，错误的是____。
A.Flink 擅长处理无界数据流，而无法对有界数据流进行高效处理
B.Flink 任务的状态始终保留在内存中，如果状态大小超过可用内存，则会保存在能高效访问的磁盘数据结构中
C.Flink 提供了多种编程语言的 API，支持复杂事件处理和机器学习
D.Flink 支持“精确一次”（exactly once）语义

15.关于数据重组的说法中,错误的是____。
A.数据重组是数据的重新生产和重新采集
B.数据重组能够使数据焕发新的光芒
C.数据重组实现的关键在于多源数据融合和数据集成
D.数据重组有利于实现新颖的数据模式创新

16.在清洗日期数据时，发现"2023 年 2 月 30 日"这样的记录，最佳处理方式是____。
A.标记为异常并人工核查
B.直接删除该记录
C.自动改为"2023 年 2 月 28 日"
D.忽略不管

17.适合使用数据脱敏的场景是____。
A.将生产数据导出用于测试环境
B.数据库备份后存放在加密硬盘中
C.将用户信息用于联邦机器学习训练
D.实时传输交易数据到总部内部服务器

18.数据要素区别于传统生产要素（如劳动力、资本）的核心特征是____。
A.可被无限复制且不损耗
B.必须通过实体介质存储
C.价值随使用次数递减
D.无法进行市场交易

19.适合图像分割任务的标注工具是____。
A.VGG Image Annotator（多边形标注）
B.LabelImg（矩形框标注）
C.Excel 表格
D.JSON 编辑器

20.时间序列预测技术可以广泛应用于大数据的数据补全方面，常见的数据预测算法不包括____。
A.K-Means
B.TimerX
C.LSTM
D.回归分析

上海市教育考试院 版权所有

二、多选题（ 本大题 10 道小题 ，每小题 2 分，共 20 分），从下面题目给出的 A、B、C、D 四个可供选择的答案中选择所有正确答案。

1.云计算的公共特征包括____。
A.快速弹性伸缩
B.按需自助服务
C.资源池化管理
D.数据本地存储

2.在 OpenStack 中，可以提供存储服务的组件包括____。
A.Cinder
B.Swift
C.Horizon
D.Nova

3.在微服务架构中，服务的独立性体现在____。
A.开发部署独立
B.技术栈独立
C.资源扩展独立
D.数据库独立

4.关于 HDFS 的副本机制，描述正确的有____。
A.默认副本数为 3
B.副本存储在同一机架以提高读写速度
C.副本策略优先跨机架存储以容灾
D.副本数可通过客户端代码动态修改

5.Zookeeper 的数据结构采用树形目录（类似 Unix 文件系统），以下描述正确的是____。
A.节点数量理论上无上限（实际受内存限制）
B.节点数据默认最大存储大小为 1MB
C.节点数据默认最大存储大小为 128MB
D.节点路径可以包含特殊字符，如“/”

6.Spark RDD 的依赖机制不包括____。
A.宽依赖
B.强依赖
C.弱依赖
D.窄依赖

7.《中华人民共和国网络安全法》对_____等方面制定了相应的规范。
A.数据的电子签名适用范围
B.数据可携权
C.数据处理者的义务
D.数据分类分级

上海市教育考试院 版权所有

8.数据集市的特点包括____。
A.存放公司的所有数据
B.专门给某个部门使用（如销售部）
C.数据已经经过清洗
D.直接从业务数据库复制数据

9.用于预测连续数值的算法或模型包括____。
A.线性回归
B.KNN（K 近邻）
C.支持向量机（SVM）
D.随机森林

10.数据流通的合法方式包括____。
A.数据交易所挂牌交易
B.未经同意转让用户隐私数据
C.企业间签订数据合作协议
D.直接售卖原始数据库文件

三、是非题（ 本大题 10 道小题 ，每小题 1 分，共 10 分）。
1.云计算中多租户隔离完全依赖物理硬件划分，虚拟化技术无法实现安全隔离。

2.OpenStack 是开源的云计算管理平台，主要用于私有云和混合云平台的部署和管理。

3.模型即服务（MaaS）是 AIaaS 的子集，允许用户直接调用已经过训练的模型。

4.Hadoop 系统的必备组件包括分布式文件系统 HDFS 和分布式数据库 HBase。

5.MapReduce 的 Shuffle 阶段是可有可无的，开发者可以跳过它直接输出结果。

6.HDFS block 的位置信息并不会做持久化，仅仅只是在 DataNode 启动时发送给 NameNode，存放在 NameNode 的内存空间中。

7.Flink 不仅能处理有界流，还能处理无界流。

8.Flink 和 SparkStreaming 都是基于事件驱动模式的流式计算框架。

9.ETL 工具的核心功能包括数据抽取、转换和保存流程。

10.传统数仓虽以批处理为主，但也可以通过微批处理或增量同步实现准实时分析（如分钟级）。

四、操作题
以下所有题目请在文件"C:\KS\大数据与云计算-答题纸E卷.doc"中作答!

上海市教育考试院 版权所有

（一）简答题（本大题2道小题，每小题5分，共10分）。

1.请简述分布式存储与集中式存储在存储结构、容灾方式和应用场景上的区别。

请在答题纸作答！此处答题一律无效！

2.应用系统在存储用户密码时，应选择数据加密还是数据脱敏，请说明原因并简述两者的目标。

请在答题纸作答！此处答题一律无效！

（二）基础操作题（本大题2道小题，每小题15分，共30分）。

1.在Docker环境中，某用户需要启动一个MySQL的容器作为应用数据库。要求以MySQL 8.0版本的镜像启动一个名为mysql的容器，为了能够持久化地保留数据库数据，需要在容器上挂载宿主机目录（/data/mysql）作为数据的实际存储位置，同时以环境变量（MYSQL_ROOT_PASSWORD）的方式设置数据库的root密码，并将容器的3306端口映射到宿主机的3306端口。请根据上述要求，补全对应的Docker命令。

启动mysql容器
docker ____(1)____ -d --name mysql
____(2)____:/var/lib/mysql *# 挂载宿主机存储目录*
____(3)____=my-secret-pw *# 设置root密码*
____(4)____ *# 映射端口*
____(5)____ *# 指定镜像*

2.在Hive的使用过程中，经常需要进行一些数据表操作和数据分析任务，涉及数据的存储、清洗、处理和导出等多个环节。具体而言，首先创建外部表以方便数据的加载，然后使用SQL语句对数据进行清洗和分析，最后获取处理结果。请根据上述要求，补全对应的Hive命令。

// 1. 创建外部表
CREATE ____(1)____ TABLE logs (ip STRING, time STRING) LOCATION '/data/logs'

// 2. 数据清洗
INSERT OVERWRITE TABLE clean_logs SELECT * FROM ____(2)____ WHERE ip IS NOT NULL

// 3. 统计TOP 10 IP
SELECT ip, ____(3)____ AS cnt FROM clean_logs GROUP BY ip ORDER BY cnt DESC ____(4)____ 10

// 4. 删除外部表

上海市教育考试院 版权所有

____(5)____ TABLE logs

请在答题纸作答！此处答题一律无效！

（三）实践应用题（本大题2道小题，每小题15分，共30分）。

1.某在线教育平台每日产生数千万条学生考试记录，原始数据存储在HDFS中（路径为hdfs://192.168.1.26:9000/input/data.txt），每条数据包含学生ID（如9000）和单科成绩（如98），以制表符（\t）分隔，数据样式如下所示。

```
9000 98
9001 99
9002 67
9003 45
9004 45
```

为评估整体教学质量，快速计算全体学生的平均成绩，但传统单机脚本因数据量过大导致处理效率低下，采用基于Hadoop生态构建分布式计算方案，通过MapReduce实现高性能批处理。为实现Map阶段和Reduce阶段的计算过程，请补全缺失的代码。

Map阶段

```
public class AvgMapper extends Mapper<LongWritable, Text, Text, FloatWritable> {
    private final static Text OUTPUT_KEY = new Text("global_avg"); // 所有记录输出同一Key
    private FloatWritable score = new FloatWritable();
    @Override
    protected void map(LongWritable key, Text value, Context context)
        throws IOException, InterruptedException {
        //1.按制表符拆分
        String[] parts = ____(1)____;
        if (parts.length == 2) {
            try {
            //2.提取成绩
                float s = Float.____(2)____;
                score.set(s);
            //3.输出：<"global_avg", 成绩>
                ____(3)____;
            } catch (NumberFormatException e) {}
        }
    }
}
```

Reduce阶段

```
public class AvgReducer extends Reducer<Text, FloatWritable, Text, FloatWritable> {
    private FloatWritable result = new FloatWritable();
    @Override
```

上海市教育考试院 版权所有

```
    protected void reduce(Text key, Iterable<FloatWritable> values, Context context)
            throws IOException, InterruptedException {
            float sum = 0;
            int count = 0;
            for (FloatWritable val : values) {
                //4.累加所有成绩
                ____(4)____;
                 count++;
            }
            //5.计算平均值
            ____(5)____;
            //6.输出：<"Average Score", 均值>
            context.write(new Text("Average Score"), result);     }
}
```

2. HDFS文件系统中存储了一份用户信息数据文件（peopleinfo.txt），该文件包含一系列个体的基本信息，每条记录包含三个字段：序号（唯一标识符）、性别（用"M"表示男性，"F"表示女性）和身高（单位为厘米）。该文件采用纯文本格式存储，以空格分隔列（例如："1 F 170"），数据文件的内容格式如下。

```
1 F 170
2 M 178
3 M 174
4 F 165
```

使用Java语言编写一个Spark应用程序，对HDFS中的peopleinfo.txt文件进行统计分析，计算出男性总数、男性平均身高和男性最高身高。

```
public class CountPeopleInfo {
    public static void main(String[] args) {
        // 1. 创建Spark配置对象
        SparkConf conf = new
SparkConf().setAppName("CountPeopleInfo").setMaster("local");
        JavaSparkContext sc = new JavaSparkContext(conf);
        // 2. 读取输入文件
        // args[0] 是输入文件路径，分片数为3
        JavaRDD<String> lines = ____(1)____
        // 3. 过滤男性数据（包含"M"的行）
        JavaRDD<String> maleInfo = lines.filter(line -> ____(2)____);
        // 4. 将男性身高转换为整数
        JavaRDD<Integer> maleHeightInfo = maleInfo.map(line -> {
            String[] parts = line.split(" ");
            return Integer. ____(3)____
```

上海市教育考试院 版权所有

```
        });
        // 5. 计算男性平均身高
        int count = maleHeightInfo.count();
        long totalHeight = maleHeightInfo.reduce((a, b) -> ___(4)___);
        double avgMale = (double) totalHeight /count;
        // 6.计算男性最高身高
        int highestMale = maleHeightInfo.reduce((a, b) -> ____(5)____);
        // 7. 输出统计结果
        System.out.println("Number of Male: " + count);
        System.out.println("Avg Male: " + avgMale);
        System.out.println("Highest Male: " + highestMale);
        sc.stop();
    }
}
```

请在答题纸作答！此处答题一律无效！

（四）场景设计与行业应用（本大题6道小题，每小题5分，共30分）。

1.某中大型电力运维企业负责区域电力设备的远程监测与负载调度。为应对设备数据激增、运维效率低下、客户满意度不高等问题，公司启动"智慧电力平台"升级工程。该工程将基于大模型（LLM）+云计算+大数据处理架构来实施。请结合上述背景，回答以下问题。

(1)公司需要建设的电流告警监控系统可以基于云计算来部署，简述云计算服务模型的分类及各类的定义。

请在答题纸作答！此处答题一律无效！

(2)为引入 AIGC 能力，公司打算在电力业务文档系统中集成大模型问答功能，需确保敏感数据安全，请写出至少两种核心数据保护方案。

请在答题纸作答！此处答题一律无效！

(3)某电力设备的运行日志文件为power_log.csv，日志格式如下所示：

设备ID,timestamp,电压(V),电流(A),位置,状态,备注,其他
E001,1714521600,220,12.3,北京,,正常运行,
E002,1714521660,270,105,上海,警告,,
E003,1714521720,,15.1,广州,正常,无,
E004,1714521780,145,8.8,深圳,正常,,
E005,1714521840,305,10.2,杭州,异常,电压过高,

请用Java或Python语言编写对该数据进行清洗的代码，并需要实现以下步骤。

1)删除缺失严重（超过50%为空）的列；

上海市教育考试院 版权所有

2)将timestamp字段转换为datetime格式；
3)将电压、电流字段转为float类型，并剔除异常值（电压不在150-300V、电流不在0-100A之间）；
4)输出清洗后数据集中的前5行数据。

请在答题纸作答！此处答题一律无效！

(4)为分析过去30天的负载高峰时段（小时），公司决定使用 Hadoop MapReduce 技术对电表数据进行分析。请说明 MapReduce 程序设计的思路，其中输入为 <timestamp, load>，输出为每小时平均负载。

请在答题纸作答！此处答题一律无效！

(5)公司拟使用Kafka + Flink实现对电表数据的实时监测与告警。请简述其整体数据流流程，并说明实时计算在电力系统中的应用优势。

请在答题纸作答！此处答题一律无效！

(6)为了保证数据质量与合规性，公司建设了数据湖，并引入数据治理流程。请简述数据治理的思路，说明数据湖相比数据仓库在数据结构方面的优势。

请在答题纸作答！此处答题一律无效！

上海市教育考试院 版权所有