2026年上海市高等学校信息技术水平考试试卷

四级 大数据与云计算（A 场）

（本试卷考试时间 150 分钟）

一、单选题（ 本大题 20 道小题 ，每小题 1 分，共 20 分），从下面题目给出的A、B、C、D四个可供选择的答案中选择一个正确答案。

1.Linux是云计算平台中常用的操作系统，其____命令可以实时监控磁盘I/O性能。

A.iostat

B.netstat

C.vmstat

D.lsof

2.____协议可用于域名解析。

A.DNS

B.ARP

C.FTP

D.SMTP

3.对象存储的核心特征是____。

A.通过唯一ID而非文件路径访问数据

B.支持块级数据的访问

C.仅适用于结构化的数据

D.必须与虚拟机绑定使用

4.Kubernetes中，资源对象____管理无状态应用。

A.Deployment

B.StatefulSet

C.DaemonSet

D.Job

5.DevOps的核心理念是持续集成和持续部署，属于CI/CD工具的是____。

A.Jenkins

B.MySQL

C.Nginx

D.Redis

6.GPU在云计算与AI场景中的主要作用是____。

A.并行计算加速

B.网络转发

C.数据加密

D.存储备份

上海市教育考试院 版权所有

7.大数据的核心价值在于____。
A.掌握庞大的数据信息
B.对含有意义的数据进行专业化处理
C.数据的存储成本降低
D.数据量的不断增长

8.MapReduce 编程模型对数据流的处理过程包含① Splitting ② Shuffling ③ Input ④ Mapping ⑤ Reducing ，正确的处理顺序是____。

A.③①④②⑤
B.①③②④⑤
C.②⑤③①④
D.④⑤①③②

9.某三甲医院拥有大量患者病历数据，希望与多家科研机构联合训练疾病预测模型，但根据《个人信息保护法》不能直接共享患者原始数据。以下最适合的技术方案是____。
A.将数据导出为 CSV 文件后通过邮件发送
B.将所有数据上传到公有云平台
C.使用联邦学习在各方本地训练模型，仅共享模型参数
D.将数据加密后存入 HDFS 供外部访问

10.____不是 Zookeeper 的功能。
A.存储大量数据
B.管理配置信息
C.管理集群节点
D.实现分布式锁

11.HBase 的数据库类型是____。
A.列式存储数据库
B.文档型数据库
C.关系型数据库
D.图数据库

12.YARN 架构中负责集群全局资源调度和管理的核心组件是____。
A.ResourceManager
B.NodeManager
C.ApplicationMaster
D.JobTracker

13.某电商平台需构建实时用户行为分析平台，数据量达 PB 级，主要场景为复杂聚合统计（如 PV/UV 统计、漏斗分析），QPS 不高但查询需秒级响应。在此场景下选用 ClickHouse 的主要原因是____。
A.高性能列式存储，通过只读取相关列大幅减少 IO，特别适合大规模数据的实时聚合分析
B.行式存储，支持高频的单行记录更新与删除操作

上海市教育考试院 版权所有

C.基于 LSM-Tree 底层，主要优势在于极高的数据写入吞吐，但聚合性能极差
D.纯单机架构，通过增加单机内存和磁盘容量即可实现无限的水平扩展和高可用

14.Apriori 算法是数据挖掘中经典的关联规则学习算法。在电商店铺的关联规则挖掘场景中，可以找出“购买啤酒的用户往往也购买尿布”这样的频繁项集。关于 Apriori 算法在这一过程中的行为，下列描述正确的是____。
A.算法利用“任意频繁项集的子集必然也是频繁的”这一先验性质，在扫描数据前就可以剪枝掉那些包含非频繁子集的候选项集
B.算法会直接生成所有可能的商品组合进行扫描，即使某些组合在之前轮次中已被证明是频繁的
C.算法在处理数据时，不依赖支持度阈值，而是完全依靠置信度来筛选规则，因此能找到蕴含关系最强的规则
D.算法一次性将所有数据加载到内存中进行分析，因此在处理 PB 级数据时性能优异，无需多轮扫描

15.关于数据重组的说法中,错误的是____。
A.数据重组是数据的重新生产和重新采集
B.数据重组能够使数据焕发新的光芒
C.数据重组实现的关键在于多源数据融合和数据集成
D.数据重组有利于实现新颖的数据模式创新

16.在清洗日期数据时，发现“2026 年 2 月 30 日”这样的记录，最佳处理方式是____。
A.标记为异常并人工核查
B.直接删除该记录
C.自动改为“2026 年 2 月 28 日”
D.忽略不管

17.适合使用数据脱敏的场景是____。
A.将生产数据导出用于测试环境
B.数据库备份后存放在加密硬盘中
C.将用户信息用于联邦机器学习训练
D.实时传输交易数据到总部内部服务器

18.数据要素区别于传统生产要素（如劳动力、资本）的核心特征是____。
A.可被无限复制且不损耗
B.必须通过实体介质存储
C.价值随使用次数递减
D.无法进行市场交易

19.某智慧交通系统需要对接全市数万个路口摄像头，实时分析车流量并在秒级内调整信号灯配时方案。以下最适合此场景的计算框架是____。
A.Hadoop MapReduce 离线批处理
B.Hive 定时批量查询
C.Flink 实时流计算

上海市教育考试院 版权所有

D.Spark SQL 交互式查询

20.时间序列预测技术可以广泛应用于大数据的数据补全方面，常见的数据预测算法不包括____。
A.K-Means
B.TimerX
C.LSTM
D.XGBoost

二、多选题（ 本大题 10 道小题 ，每小题 2 分，共 20 分），从下面题目给出的 A、B、C、D 四个可供选择的答案中选择所有正确答案。

1.云计算的公共特征包括____。
A.快速弹性伸缩
B.按需自助服务
C.资源池化管理
D.数据本地存储

2.在 OpenStack 中，可以提供存储服务的组件包括____。
A.Cinder
B.Swift
C.Horizon
D.Neutron

3.在微服务架构中，服务的独立性体现在____。
A.开发部署独立
B.技术栈独立
C.资源扩展独立
D.数据库独立

4.关于 HDFS 的副本机制，描述正确的有____。
A.默认副本数为 3
B.副本存储在同一机架以提高读写速度
C.副本策略优先跨机架存储以容灾
D.副本数可通过客户端代码动态修改

5.Zookeeper 的数据结构采用树形目录（类似 Unix 文件系统），以下描述正确的是____。
A.节点数量理论上无上限（实际受内存限制）
B.节点数据默认最大存储大小为 1MB
C.节点数据默认最大存储大小为 128MB
D.节点路径可以包含特殊字符，如“/”

6.以下属于深度学习模型架构的有_____。
A.卷积神经网络(CNN)
B.循环神经网络(RNN)

上海市教育考试院 版权所有

C.Transformer
D.生成对抗网络(GAN)

7.《中华人民共和国网络安全法》对_____等方面制定了相应的规范。
A.数据的电子签名适用范围
B.数据可携权
C.数据处理者的义务
D.数据分类分级

8.数据集市的特点包括____。
A.存放公司的所有数据
B.专门给某个部门使用（如销售部）
C.数据已经经过清洗
D.直接从业务数据库复制数据

9.用于预测连续数值的算法或模型包括____。
A.线性回归
B.KNN（K 近邻）
C.支持向量机（SVM）
D.随机森林

10.数据流通的合法方式包括____。
A.数据交易所挂牌交易
B.未经同意转让用户隐私数据
C.企业间签订数据合作协议
D.直接售卖原始数据库文件

三、是非题（ 本大题 10 道小题，每小题 1 分，共 10 分）。
1.云计算中多租户隔离完全依赖物理硬件划分，虚拟化技术无法实现安全隔离。

2.OpenStack 是开源的云计算管理平台，主要用于私有云和混合云平台的部署和管理。

3.根据《中华人民共和国数据安全法》，我国对数据实行分类分级保护制度。

4.Hadoop 系统的必备组件包括分布式文件系统 HDFS 和分布式数据库 HBase。

5.MapReduce 的 Shuffle 阶段是可有可无的，开发者可以跳过它直接输出结果。

6.HDFS block 的位置信息并不会做持久化，仅仅只是在 DataNode 启动时发送给 NameNode，存放在 NameNode 的内存空间中。

7.Flink 不仅能处理有界流，还能处理无界流。

8.传统的 Hadoop FIFO 调度器不支持现代意义上基于多个独立资源池（Pool/Queue）的并

上海市教育考试院 版权所有

行提交和资源隔离。而先进的 Capacity 调度器原生支持多 Pool 提交。

9. ETL 工具的核心功能包括数据抽取、转换和保存流程。

10. 传统数仓虽以批处理为主，但也可以通过微批处理或增量同步实现准实时分析（如分钟级）。

四、操作题

以下所有题目请在文件"C:\KS\大数据与云计算-答题纸E卷.doc"中作答!

（一）简答题（本大题2道小题，每小题5分，共10分）。

1. 请简述分布式存储与集中式存储在存储结构、容灾方式和应用场景上的区别。

请在答题纸作答！此处答题一律无效！

2. 应用系统在存储用户密码时，应选择数据加密还是数据脱敏，请说明原因并简述两者的目标。

请在答题纸作答！此处答题一律无效！

（二）基础操作题（本大题2道小题，每小题15分，共30分）。

1. 在Docker环境中，某用户需要启动一个MySQL的容器作为应用数据库。要求以MySQL 8.0版本的镜像启动一个名为mysql的容器，为了能够持久化地保留数据库数据，需要在容器上挂载宿主机目录（/data/mysql）作为数据的实际存储位置，同时以环境变量（MYSQL_ROOT_PASSWORD）的方式设置数据库的root密码，并将容器的3306端口映射到宿主机的3306端口。

请根据上述要求，补全对应的Docker命令。

#启动mysql容器
docker ____(1)____ -d --name mysql
____(2)____:/var/lib/mysql # 挂载宿主机存储目录
____(3)____=my-secret-pw # 设置root密码
____(4)____ # 映射端口
____(5)____ # 指定镜像

请在答题纸作答！此处答题一律无效！

2. 在Hive的使用过程中，经常需要进行一些数据表操作和数据分析任务，涉及数据的存储、清洗、处理和导出等多个环节。具体而言，首先创建外部表以方便数据的加载，然后

上海市教育考试院 版权所有

使用SQL语句对数据进行清洗和分析，最后获取处理结果。

请根据上述要求，补全对应的HQL命令。

```
//创建外部表
CREATE ____(1)____ TABLE logs (ip STRING, time STRING) LOCATION
'/data/logs'

//数据清洗
INSERT OVERWRITE TABLE clean_logs SELECT * FROM ____(2)____ WHERE ip
IS NOT NULL

//统计TOP 10 IP
SELECT ip, ____(3)____ AS cnt FROM clean_logs GROUP BY ip ORDER BY cnt
DESC ____(4)____ 10

//删除外部表
____(5)____ TABLE logs
```

请在答题纸作答！此处答题一律无效！

（三）实践应用题（本大题2道小题，每小题15分，共30分）。

1.某在线教育平台每日产生数千万条学生考试记录，原始数据存储在HDFS中，每条数据包含学生ID（如9000）和单科成绩（如98），以制表符（\t）分隔，数据样式如下所示。

```
9000  98
9001  99
9002  67
9003  45
9004  45
```

为评估整体教学质量，快速计算全体学生的平均成绩，传统单机脚本因数据量过大导致处理效率低下，采用基于Hadoop生态构建分布式计算方案，通过MapReduce实现高性能批处理。

为实现Map阶段和Reduce阶段的计算过程，请补全缺失的代码。

Map阶段

上海市教育考试院 版权所有

```
public class AvgMapper extends Mapper<LongWritable, Text, Text, FloatWritable> {
    // 所有记录输出同一Key
    private final static Text OUTPUT_KEY = new Text("global_avg");
    private FloatWritable score = new FloatWritable();
    @Override
    protected void map(LongWritable key, Text value, Context context)
        throws IOException, InterruptedException {
        //按制表符拆分
        String[] parts = ____(1)____;
        if (parts.length == 2) {
            try {
            //提取成绩
                float s = Float.____(2)____;
                score.set(s);
            //输出：<"global_avg", 成绩>
                ____(3)____;
            } catch (NumberFormatException e) {}
        }
    }
}
```

Reduce阶段

```
public class AvgReducer extends Reducer<Text, FloatWritable, Text, FloatWritable> {
    private FloatWritable result = new FloatWritable();
    @Override
    protected void reduce(Text key, Iterable<FloatWritable> values, Context context)
        throws IOException, InterruptedException {
        float sum = 0;
        int count = 0;
        for (FloatWritable val : values) {
            //累加所有成绩
            ____(4)____;
            count++;
        }
        //计算平均值
        ____(5)____;
        //输出：<"Average Score", 均值>
        context.write(new Text("Average Score"), result);      }
```

上海市教育考试院 版权所有

}

请在答题纸作答！此处答题一律无效！

2. HDFS文件系统中存储了一份用户信息数据文件（peopleinfo.txt），该文件包含一系列个体的基本信息，每条记录包含三个字段：序号（唯一标识符）、性别（用"M"表示男性，"F"表示女性）和身高（单位为厘米）。该文件采用纯文本格式存储，以空格分隔列（例如："1 F 170"），数据文件的内容格式如下。

```
1 F 170
2 M 178
3 M 174
4 F 165
```

使用Java语言编写一个Spark应用程序，对HDFS中的peopleinfo.txt文件进行统计分析，计算出男性总数、男性平均身高和男性最高身高。

请补全缺失的代码。

```
public class CountPeopleInfo {
    public static void main(String[] args) {
        //创建Spark配置对象
        SparkConf conf = new
SparkConf().setAppName("CountPeopleInfo").setMaster("local");
        JavaSparkContext sc = new JavaSparkContext(conf);
        //读取输入文件
        // args[0] 是输入文件路径，分片数为3
        JavaRDD<String> lines = ____(1)____
        //过滤男性数据（包含"M"的行）
        JavaRDD<String> maleInfo = lines.filter(line -> ____(2)____);
        //将男性身高转换为整数
        JavaRDD<Integer> maleHeightInfo = maleInfo.map(line -> {
            String[] parts = line.split(" ");
            return Integer. ____(3)____
        });
        //计算男性平均身高
        int count = maleHeightInfo.count();
        long totalHeight = maleHeightInfo.reduce((a, b) -> ___(4)___);
```

上海市教育考试院 版权所有

```
            double avgMale = (double) totalHeight /count;
            //计算男性最高身高
            int highestMale = maleHeightInfo.reduce((a, b) -> ____(5)____);
            //输出统计结果
            System.out.println("Number of Male: " + count);
            System.out.println("Avg Male: " + avgMale);
            System.out.println("Highest Male: " + highestMale);
            sc.stop();
        }
}
```

请在答题纸作答！此处答题一律无效！

（四）场景设计与行业应用（本大题6道小题，每小题5分，共30分）。

1. 某大型城市轨道交通集团正在构建“智慧轨道云大脑”，旨在通过数据驱动提升运营效率与安全水平。该系统架构如下：

- 混合云部署策略：
  - 核心控制区：列车信号控制系统（CBTC）及高敏感工艺数据部署在私有云，以保障数据主权和低延迟。
  - 公共服务区：面向乘客的APP后端、历史大数据分析平台及AI模型训练部署在公有云，以应对弹性算力需求。
- 数据存储架构：
  - 非结构化文件区：存放数百万份PDF检修文档、工程图纸CAD文件以及全天候监控视频。这些数据体量大（单次上传GB级），上传后极少修改，主要通过URL快速读取。
  - 时序数据区：存放列车传感器每秒产生的振动、温度、速度等高频遥测数据。这些数据写入频率极高，且主要进行顺序追加写入。
- 分布式协调服务：为了协调分布在城市各站的信号控制器与中央调度服务器，系统引入了Zookeeper作为分布式协调服务，负责管理集群中的配置信息。
- 数据治理：由于隧道通信干扰，传感器数据偶尔会出现时间序列缺失（如某分钟数据丢失），影响后续的趋势分析建模，需进行缺失值处理。
- AI 模型评估：系统训练了一个❽车门故障检测❾模型（分类任务）。

上海市教育考试院 版权所有

- 在测试集上，模型有 100 次预测：其中真实故障 20 次，真实正常 80 次。
- 模型正确预测出 15 次故障，误报（正常判为故障）5 次；漏报（故障判为正常）5 次；正确预测正常 75 次。

请结合上述背景，回答以下问题。

(1) 场景中提到“核心控制区”使用私有云，“公共服务区”使用公有云。请从资产归属、安全性和扩展性的角度简述公有云和私有云的区别。

请在答题纸作答！此处答题一律无效！

(2) 平台决定将PDF检修文档、工程图纸等非结构化大文件存储在对象存储（OSS）中，而非 HDFS 中。请结合 HDFS的NameNode（元数据管理） 和 数据块（Block） 机制，简述为什么“海量小文件或大型静态文档”不适合存储在HDFS中。

请在答题纸作答！此处答题一律无效！

(3) 场景中提到使用Zookeeper进行协调。当集群发生网络分区时，Zookeeper是通过什么核心机制保证数据一致性的。

请在答题纸作答！此处答题一律无效！

(4) 场景中提到传感器数据出现缺失。如果直接删除这些时间点，对“趋势分析”有何影响？请提出一种合理的缺失值填补方法并说明理由。

请在答题纸作答！此处答题一律无效！

(5) 在时序数据区的架构设计中，平台决定使用HBase来存储列车的实时轨迹数据（A类数据）。请结合HBase的技术特点，简述使用该数据库的三个核心理由。

请在答题纸作答！此处答题一律无效！

(6) 场景中的“车门故障检测”是一个机器学习的二分类任务。对于“车门故障”这种关键安全指标，我们认为“漏报”（未检测出故障）的后果远重于“误报”（误报故障）。因此，在调整模型阈值以优化性能时，我们是更希望提高准确率(Precision)还是召回率(Recall)？请结合定义说明理由。

上海市教育考试院 版权所有

请在答题纸作答！此处答题一律无效！

上海市教育考试院
版权所有